

Anexo técnico: multiplicação de matrizes

SSC0951 — Desenvolvimento de Código Otimizado

Coleta: 08/09/2026 • Entrega prevista: 09/09/2026

Fernando Alee Suaiden — USP 12680836; Bruno Dalcantoni Cozac — USP 13686323

1. Objetivo e configurações

Comparar quatro implementações seriais de multiplicação de matrizes com dois modos de alocação, medindo tempo, leituras e faltas em L1 de dados, instruções de desvio e erros de predição. O enunciado define oito experimentos [1]; as versões calculam a mesma multiplicação, alterando a ordem e a organização dos laços.

Exp.	Técnica	Alocação	Laços / transformação
1	Simple	Estática	$i \rightarrow j \rightarrow k$
2	Simple	Dinâmica	$i \rightarrow j \rightarrow k$
3	Interchange	Estática	$i \rightarrow k \rightarrow j$
4	Interchange	Dinâmica	$i \rightarrow k \rightarrow j$
5	Unrolling	Estática	$i \rightarrow j \rightarrow k$; fator 2 em k
6	Unrolling	Dinâmica	$i \rightarrow j \rightarrow k$; fator 2 em k
7	Tiling	Estática	Blocos 32^3 ; $i \rightarrow j \rightarrow k$ internos
8	Tiling	Dinâmica	Blocos 32^3 ; $i \rightarrow j \rightarrow k$ internos

$$R[i][j] = \sum_{k=0}^{N-1} A[i][k] \times B[k][j]$$

Foram realizadas **80 execuções válidas**, dez por configuração. Todas utilizaram matrizes 512×512 de **float**, entradas idênticas e compilação **-O0**. A melhor média observada foi a do experimento 3: **0,387 ± 0,100 s** (média ± margem do IC95%).

Os resultados descrevem esta implementação, neste computador e protocolo. Contagens menores de uma métrica não implicam, isoladamente, menor tempo de execução.

2. Ambiente, implementação e coleta

Item	Configuração registrada
Processador	AMD Ryzen 7 5700U; 8 núcleos, 16 CPUs lógicas
Caches	L1d: 32 KiB por núcleo; L2: 512 KiB por núcleo; L3: 8 MiB no total (lscpu)
Sistema	Fedora Linux 43; kernel 7.1.13-100.fc43.x86_64
Compilador	GCC 15.3.1; -std=c11 -g -O0 -Wall -Wextra -Werror
Perfilador	perf version 7.1.13-100.fc43.x86_64; pacote oficial Fedora, extraído localmente
Execução	Uma thread; afinidade na CPU lógica 2; CPU irmã 3 não isolada
Frequência	Governador: powersave; boost ativo, sem travar frequência

Memória. As matrizes estáticas têm armazenamento **static** e disposição contígua; as dinâmicas usam **float ****, vetor de ponteiros e uma alocação por linha. As funções recebem a saída e a zeram a cada chamada. O fator alocação representa também diferenças de disposição e acesso por ponteiros, e não apenas o custo de malloc.

Transformações. Interchange troca os laços j e k. Unrolling expande duas operações consecutivas do laço k e trata o resto ímpar. Tiling percorre blocos nas três dimensões, preserva i-j-k dentro deles e limita as bordas. Não se utilizam pragmas, OpenMP ou paralelismo.

Escopo. O cronômetro CLOCK_MONOTONIC mede zeramento da saída e multiplicação. O perf inicia desativado; o programa envia enable, aguarda confirmação, cronometra o cálculo e envia disable. Os contadores incluem um pequeno custo de controle e leitura do relógio ao redor do cálculo, mas excluem geração das entradas, alocação, checksum e impressão [3].

Eventos. L1-dcache-loads:u, L1-dcache-load-misses:u, branch-instructions:u e branch-misses:u foram agrupados e medidos apenas em modo usuário. Todos tiveram cobertura de 100%, sem multiplexação. Não houve alteração de permissões do kernel (perf_event_paranoid=2).

Ordem e repetições. Dez rodadas, cada uma contendo E1-E8 em ordem sorteada com semente 9512026. Execuções exploratórias anteriores não integram a amostra de 80 medições. Cada observação usa um processo novo, sem chamada de aquecimento interna. A primeira escrita na saída integra a medição. Nenhuma observação definitiva foi descartada.

3. Validação e tratamento estatístico

Correção. As oito funções foram comparadas elemento a elemento com uma referência em double, usando matrizes densas com sinais e frações, identidade e zero. Os testes cobrem N=1, 2, 3, 10, 32, 33 e 65, blocos 32 e 7 e chamadas repetidas. AddressSanitizer e verificações de comportamento indefinido passaram para os casos registrados. Tamanhos ímpares e blocos incompletos são tratados.

Todas as 80 execuções medidas produziram checksum **33566647.392028809**. O checksum verifica a consistência da campanha; a validação matemática é feita pelos testes independentes. Os arquivos brutos, fontes utilizadas e hashes SHA-256 foram preservados.

Média e IC95%. Para cada configuração e cada uma das cinco métricas, calculou-se a média, o desvio padrão amostral (denominador n-1) e o intervalo bilateral pela distribuição t de Student [4].

$$IC95\% = \text{média} \pm t_{0,975; n-1} \times s / \sqrt{n}$$

Com n=10, o valor crítico é 2,262157. Nas tabelas, “±” indica a **margem do intervalo da média**, não o desvio padrão nem a faixa de execuções. Os limites completos e os dados com precisão integral estão em resumo.csv. Os intervalos são individuais, sem ajuste para comparações múltiplas.

Influências. Foram escolhidos previamente os conjuntos E1,E2,E3,E4 para cache e E1,E2,E5,E6 para branch. Em cada análise 2², A é a técnica (-1 simples, +1 otimizada), B é a alocação (-1 estática, +1 dinâmica), e AB é a interação [5].

$$y = q_0 + q_A A + q_B B + q_{AB} AB + \text{erro}$$

Os coeficientes são obtidos pelos contrastes das quatro médias divididos por 4. Cada efeito é 2q. Com r=10 réplicas por célula: $SQ_A = 4rq_A^2$, analogamente para B e AB; SQ_{erro} é a soma dos quadrados dos desvios dentro de cada célula.

$$SQ_{\text{total}} = SQ_A + SQ_B + SQ_{AB} + SQ_{\text{erro}}$$

A influência com réplicas é $100 \times SQ_{\text{fator}} / SQ_{\text{total}}$. Também é apresentada a normalização somente entre as quatro médias: $100 \times q_{\text{fator}}^2 / (q_A^2 + q_B^2 + q_{AB}^2)$. Esta segunda forma soma 100% entre os fatores, mas omite a variação entre repetições. Percentual de influência não é percentual de melhoria de desempenho.

A análise foi conferida em R 4.5.3 com uma adaptação do script fornecido em r.txt [6]: planejamento 2² explícito, lm, anova e normalização pelas três Mean Sq. As 40 médias, desvios e ICs e as 12 influências de cada normalização coincidiram com Python dentro das tolerâncias registradas. Para o ajuste das quatro médias, há zero graus de liberdade residuais; não se interpretam testes F desse modelo [7].

4. Comparação dos tempos dos oito experimentos




Figura 1 — Médias e intervalos de confiança de 95% para o tempo do cálculo.

Exp.	Técnica / alocação	Tempo (s), média ± IC95%	Razão simples / versão
1	Simples / estática	0,534 ± 0,116	1,000×
2	Simples / dinâmica	0,587 ± 0,123	1,000×
3	Interchange / estática	0,387 ± 0,100	1,381×
4	Interchange / dinâmica	0,582 ± 0,124	1,009×
5	Unrolling / estática	0,448 ± 0,093	1,192×
6	Unrolling / dinâmica	0,616 ± 0,134	0,953×
7	Tiling / estática	0,419 ± 0,098	1,275×
8	Tiling / dinâmica	0,565 ± 0,115	1,040×

O interchange estático (E3) reduziu o tempo médio em **27,6%** em relação a E1, razão de 1,38×. As médias estáticas seguiram a ordem $E3 < E7 < E5 < E1$.

Na alocação dinâmica, E8 teve a menor média: $0,565 \pm 0,115$ s, redução de 3,8% ante E2. E6 teve média 4,9% maior que E2. Seus intervalos se sobrepõem; essas razões são descritivas e não constituem testes de significância.

O custo de carregar ponteiros por linha e a geração de endereços em -O0 podem contribuir para as diferenças entre versões estáticas e dinâmicas. O perfilamento obtido não isola esses mecanismos nem prova uma causa única.

5. Leituras e faltas na cache L1 de dados




Figura 2 — Contagens de cache para as oito configurações; barras de IC95%.

Exp.	L1 loads (milhões), média ± IC95%	L1 misses (milhões), média ± IC95%
1	2.431,673 ± 1,029	136,701 ± 0,045
2	3.100,986 ± 0,205	141,394 ± 0,345
3	2.427,550 ± 0,075	8,673 ± 0,008
4	3.098,614 ± 0,059	8,773 ± 0,017
5	2.299,933 ± 1,639	137,124 ± 0,042
6	2.902,646 ± 0,418	143,973 ± 0,320
7	2.588,463 ± 0,210	138,718 ± 0,046
8	3.128,285 ± 0,247	1,932 ± 0,152

Interchange diminuiu as faltas de L1 de 136,70 para 8,67 milhões na alocação estática (**93,7%**) e de 141,39 para 8,77 milhões na dinâmica (**93,8%**). A ordem i-k-j percorre linhas de B e da saída no laço interno, coerente com maior localidade.

O total de loads permanece elevado. Esses eventos abrangem as leituras executadas pelo código, inclusive acessos a variáveis e ponteiros em -O0; não equivalem apenas ao número de elementos matemáticos de A e B.

O tiling apresentou forte diferença: E7 teve 138,72 milhões de faltas e E8, 1,93 milhões. Uma hipótese é conflito de conjuntos causado pelo passo de 2.048 bytes entre linhas estáticas e pela ordem interna i-j-k; as linhas dinâmicas têm disposição distinta. Seriam necessários outros tamanhos, blocos ou medidas de endereços para confirmar. Não se conclui que tiling sempre melhora cache.

6. Instruções de desvio e erros de predição




Figura 3 — Contagens de branch; o número de desvios e o de erros são métricas distintas.

Exp.	Branch instr. (milhões), média ± IC95%	Branch misses (milhares), média ± IC95%
1	135,27130 ± 0,00012	264,327 ± 0,229
2	135,27109 ± 0,00012	264,235 ± 0,172
3	135,27115 ± 0,00010	263,940 ± 0,119
4	135,27109 ± 0,00013	264,163 ± 0,147
5	68,42449 ± 0,00010	264,139 ± 0,147
6	68,42441 ± 0,00013	264,281 ± 0,268
7	147,48992 ± 0,00010	138,133 ± 0,397
8	147,48981 ± 0,00012	138,018 ± 0,348

O unrolling reduziu as instruções de desvio de cerca de 135,271 para 68,424 milhões: **49,42%** na alocação estática e 49,42% na dinâmica. Isso é coerente com metade das iterações de controle do laço k, preservando as multiplicações.

Os erros de predição de E1,E2,E5,E6 ficaram próximos de 264,2 mil. Assim, diminuir quase pela metade o total de desvios não reduziu os erros na mesma proporção. A razão entre as médias de misses e instructions passou de 0,195% em E1 para 0,386% em E5; essa taxa é descritiva, sem IC específico.

Tiling aumentou o total de instruções de desvio devido aos laços de bloqueio, mas apresentou menos erros de predição. A mudança no padrão de controle pode explicar parte do comportamento. Como cache, acessos e controle mudam conjuntamente, uma só contagem não explica o tempo final.

7. Influência dos fatores e da interação




Figura 4 — Decomposição com réplicas: técnica, alocação, interação e resíduo.

Métrica	Técnica (%)	Alocação (%)	Interação (%)	Resíduo (%)
L1 loads	0,002	99,997	0,000	0,000
L1 misses	99,934	0,034	0,031	0,001
Branch instr.	100,000	0,000	0,000	0,000
Branch misses	1,527	0,190	4,188	94,095

Tabela 5 — Percentuais da soma de quadrados total das 40 observações de cada subconjunto. Valores exibidos como 0,000% podem ser positivos abaixo da precisão de apresentação.

Métrica	Técnica (%)	Alocação (%)	Interação (%)
L1 loads	0,002	99,997	0,000
L1 misses	99,935	0,034	0,031
Branch instr.	100,000	0,000	0,000
Branch misses	25,866	3,217	70,918

Tabela 6 — Método do script R de apoio: normalização entre as quatro médias, sem componente de erro. Valores conferidos por lm e anova em R; cada fator tem um grau de liberdade, portanto Mean Sq = Sum Sq.

Cache (E1-E4). A alocação explica 99,997% da variação total em loads; a técnica explica 99,934% em misses. Em média sobre as duas técnicas, mudar de estática para dinâmica acrescentou 670,19 milhões de loads. Interchange reduziu, em média sobre as alocações, 130,32 milhões de misses.

Branch (E1,E2,E5,E6). A técnica responde por praticamente 100% da variação nas instruções de desvio. Já em branch misses, **94,09% é resíduo entre repetições**. O efeito médio do unrolling foi de apenas -70,8 erros por execução. A influência da interação parece maior quando o erro é omitido; não se deve interpretar esse percentual como evidência forte de ganho.

8. Efeitos principais e interação — cache




Figura 5 — E1-E4. À esquerda e ao centro: médias marginais sobre o outro fator. À direita: médias de cada combinação com IC95%. Os eixos verticais têm escalas próprias.

Os gráficos complementam os percentuais das Tabelas 5 e 6, seguindo os efeitos principais e de interação apresentados pelo material de apoio. O planejamento explicita a correspondência entre cada experimento e os níveis da técnica e da alocação; não se depende da ordem implícita de um vetor de respostas.

Em L1 loads, a linha do efeito de alocação apresenta a maior mudança: o acesso dinâmico exige mais leituras. No gráfico de interação, a distância entre as duas alocações é quase constante entre simples e interchange, coerente com o componente de interação muito pequeno.

Em L1 misses, ambas as alocações apresentam uma queda acentuada com interchange. As diferenças entre estática e dinâmica são maiores no caso simples e se tornam pequenas após a troca dos laços. Essa diferença entre efeitos condicionais corresponde ao termo de interação, embora ele represente apenas uma pequena parcela da variação total.

Os painéis de efeitos principais mostram médias marginais, não o resultado de uma única configuração. Uma linha visualmente inclinada não implica, por si só, grande efeito: é preciso considerar a escala do eixo e os valores numéricos.

9. Efeitos principais e interação — branch




Figura 6 — E1,E2,E5,E6. Médias marginais e interação. As barras à direita são IC95% individuais; os eixos verticais têm escalas próprias.

Em branch instructions, o efeito do unrolling é grande nas duas alocações. As médias estática e dinâmica praticamente coincidem quando a técnica é fixada. A pequena inclinação do painel central decorre de diferenças de poucas dezenas de eventos sobre dezenas de milhões, e não de uma alteração relevante no total de desvios.

Em branch misses, as linhas da interação se cruzam: o unrolling diminuiu a média na alocação estática e aumentou ligeiramente a média na dinâmica. As diferenças são pequenas em escala absoluta e seus intervalos apresentam sobreposição. A decomposição com réplicas atribui 94,09% da variação total ao resíduo; não se afirma uma melhora geral dos erros de predição.

A Figura 6 ajuda a interpretar por que a interação corresponde a 70,92% quando o denominador inclui apenas a variação entre quatro médias, mas a 4,19% quando inclui também a variação entre execuções. O script de apoio usa o primeiro denominador. Ambos foram mantidos e identificados para evitar confundir influência relativa com tamanho do ganho.

A execução em R também produziu efeitos_interacoes_R.pdf com os gráficos básicos de efeitos e interação, além das tabelas ANOVA e dos coeficientes. As figuras deste relatório utilizam os mesmos dados, com apresentação em Matplotlib e ICs adicionados aos painéis de interação.

10. Variabilidade, limites e conclusões




Figura 7 — As primeiras observações de alguns experimentos foram mais lentas e foram preservadas.

A primeira rodada teve média de 0,937 s por execução; da terceira em diante, 0,461 s. A mudança sugere condições de execução diferentes durante a campanha. Os dados não incluem frequência, temperatura e carga por execução, portanto não permitem determinar a causa. Nenhuma observação foi removida.

A afinidade reduz migrações entre núcleos, mas não elimina disputa com processos do sistema, uso da CPU irmã, variação de frequência ou efeitos térmicos. Os processos foram registrados no início e no fim da coleta. O processo firefox apareceu nos dois registros. O notebook estava na bateria nos dois momentos. Esses registros não medem a carga instantânea de cada aplicativo. O boost permaneceu ativo e o núcleo não foi isolado. A ordem sorteada distribui parte desses efeitos, mas não garante independência perfeita.

Os ICs t pressupõem observações suficientemente independentes e distribuição das médias adequadamente aproximada; com dez repetições, assimetria e variações de estado da máquina podem afetar essa aproximação. Os intervalos refletem também a mudança de tempo observada durante a campanha; a hipótese de condições estáveis fica enfraquecida. Não foram removidos valores extremos, nem feitas repetições seletivas.

N=512 gera três matrizes de aproximadamente 3 MiB no total, acima da L1d e L2 de um núcleo. BLOCO=32 e fator de unrolling 2 foram fixados, sem busca pelo melhor ajuste. A dimensão é potência de dois e pode acentuar conflitos de cache. Os resultados não descrevem todos os tamanhos e blocos possíveis.

As medições incluem zeramento e primeira escrita da saída; excluem o tempo de malloc/free e usam apenas eventos de usuário. Portanto, a comparação de alocação avalia principalmente os acessos e a disposição das matrizes, não o custo total de criação de estruturas. Os percentuais de influência dependem dos níveis e subconjuntos escolhidos.

Conclusões. Interchange estático apresentou o menor tempo médio e reduziu fortemente as faltas de L1. Unrolling diminuiu as instruções de desvio em aproximadamente metade, mas isso não garantiu melhora no caso dinâmico. Tiling dependeu fortemente da disposição em memória. A análise com réplicas mostrou que a variação em branch misses foi dominada pelo resíduo, exigindo cautela para atribuir efeitos aos fatores.

11. Reprodutibilidade e referências

Os dados desta versão estão em **dados/coleta_vscode/**. O diretório contém `medicoes.csv` (80 linhas), `metadados.json` (máquina, versões, ordem e hashes), `brutos/` (saída original do perf e do programa) e `fontes/` (cópia dos arquivos usados na coleta).

Em `analise/`: `resumo.csv` contém as 40 combinações experimento/métrica com média, desvio, limites do IC, mínimo, máximo e CV; `influencias.csv` e `influencias.json` guardam os efeitos e somas de quadrados; `graficos/` contém PNG e PDF vetorial. O piloto está preservado em `historico/piloto.zip` e não entra nos cálculos.

Os programas de coleta, análise e geração do relatório estão em `scripts/`. Para recalcular a análise dos dados existentes:

```
make relatorio COLETA=./dados/coleta_vscode
```

Uma nova coleta deve usar um diretório novo, após compilar com `TAMANHO=512` e `BLOCO=32`. O coletor recusa sobrescrever uma coleta existente e exige pelo menos dez rodadas no modo definitivo. Um arquivo de dados incompleto, checksum divergente, contador indisponível ou multiplexado interrompe a validação.

A instalação do perf no sistema exigiu senha; utilizou-se o pacote Fedora `perf-7.1.13-100.fc43.x86_64`, com assinatura verificada, extraído em `.ferramentas/perf/`. Não foram alterados pacotes do sistema ou permissões de contadores. O ambiente Python local usa NumPy 2.2.6 compatível com SciPy 1.14.1. A conferência em R 4.5.3 utiliza uma cópia local do pacote oficial R-core e da biblioteca tre; não exige FrF2, pois as quatro combinações são explicitadas.

Referências

- [1] SSC0951. Atividade relativa à aula 3 (Profiling). Arquivo local `Atividade_1.pdf`. Enunciado, métricas, repetições, IC95% e entrega.
- [2] BRUSCHI, Sarita Mazzini. 3ª aula — Técnicas básicas para otimização de código serial / Profiling. Arquivo local `3aAula_Profiling.pdf`, páginas 14–17.
- [3] Linux perf. `perf-stat(1)`: controle enable/disable, --delay e grupos de eventos. man7.org/linux/man-pages/man1/perf-stat.1.html. Consulta: 07/09/2026.
- [4] NIST/SEMATECH. Confidence Limits for the Mean. *NIST e-Handbook*, seção 1.3.5.2. Consulta: 07/09/2026.
- [5] NIST/SEMATECH. The two-way ANOVA. *NIST e-Handbook*, seção 7.4.2.7. Consulta: 07/09/2026.
- [6] SSC0951. Script R de apoio para cálculo das influências. Arquivo fornecido pelo grupo: `r.txt`; cópia preservada em `material_apoio/r_original.txt`. Conferido em 08/09/2026.
- [7] R Core Team. ANOVA for Linear Model Fits. *Documentação de anova.lm*. Consulta: 08/09/2026.

Identificação: Fernando Alee Suaiden — USP 12680836; Bruno Dalcantoni Cozac — USP 13686323