

Multiplicação de matrizes e análise de desempenho

SSC0951 — Desenvolvimento de Código Otimizado

Coleta: 08/09/2026

Fernando Alee Suaiden — Nº USP 12680836

Bruno Dalcantoni Cozac — Nº USP 13686323

1. O que foi feito

Foram comparadas quatro implementações seriais da multiplicação de matrizes, cada uma com alocação estática e dinâmica, totalizando os oito experimentos do enunciado [1]. Cada elemento da saída soma os produtos de uma linha de A por uma coluna de B.

Estática	Dinâmica	Técnica	Implementação
E1	E2	Simples	Laços $i \rightarrow j \rightarrow k$
E3	E4	Interchange	Troca para $i \rightarrow k \rightarrow j$
E5	E6	Unrolling	Duas operações por iteração de k
E7	E8	Tiling	Blocos de 32 em cada dimensão

Configuração. Matrizes 512×512 de float, entradas idênticas e compilação GCC 15.3.1 com -O0 em todas as versões. Unrolling e tiling são explícitos, sem OpenMP. As matrizes estáticas são contíguas; as dinâmicas usam um vetor de ponteiros e uma alocação por linha.

Máquina. AMD Ryzen 7 5700U (8 núcleos/16 CPUs lógicas), Fedora 43, kernel e perf 7.1.13. A L1 de dados tem 32 KiB por núcleo e a L2, 512 KiB. O programa usou uma thread fixada na CPU lógica 2. Frequência e boost permaneceram sob controle do sistema.

Coleta. Foram feitas dez rodadas com os oito experimentos em ordem sorteada: **80 medições**. O piloto foi separado. O tempo mede zeramento da saída e multiplicação. Os quatro contadores do perf foram ativados ao redor desse trecho, em modo usuário, excluindo alocação, geração das entradas e impressão, com pequeno custo de controle [3]. Todos tiveram cobertura de 100%, sem multiplexação. Nenhuma execução foi descartada.

Validação. As oito versões passaram em testes contra uma referência em double, com matrizes densas, identidade e zero, tamanhos ímpares, blocos incompletos e chamadas repetidas. As 80 medições tiveram o mesmo checksum.

Estatística. Para cada métrica e experimento, calculou-se média e intervalo de confiança de 95%: média $\pm 2,262157 \times s/\sqrt{10}$, com desvio padrão amostral e t de Student com nove graus de liberdade [4]. Nas tabelas, “ $\pm$ ” indica a margem desse intervalo. Os cálculos também foram conferidos em R.

2. Comparação dos tempos




Figura 1 — Tempo médio do cálculo e intervalo de confiança de 95%; dez execuções por configuração.

Exp.	Técnica / alocação	Tempo (s): média ± IC95%	Razão simples / versão
E1	Simple / estática	0,534 ± 0,116	1,000×
E2	Simple / dinâmica	0,587 ± 0,123	1,000×
E3	Interchange / estática	0,387 ± 0,100	1,381×
E4	Interchange / dinâmica	0,582 ± 0,124	1,009×
E5	Unrolling / estática	0,448 ± 0,093	1,192×
E6	Unrolling / dinâmica	0,616 ± 0,134	0,953×
E7	Tiling / estática	0,419 ± 0,098	1,275×
E8	Tiling / dinâmica	0,565 ± 0,115	1,040×

Melhor resultado: interchange estático (E3), com $0,387 \pm 0,100$ s. O tempo médio foi 27,6% menor que o de E1, equivalente a uma razão de 1,38×. Na alocação estática, todas as técnicas tiveram média menor que a versão simples.

Na alocação dinâmica, tiling (E8) teve a menor média: redução de 3,8% em relação a E2. Unrolling dinâmico (E6) teve média 4,9% maior que E2. Os intervalos de E6 e E2 se sobrepõem; as razões apresentadas são comparações descritivas, não testes de significância.

A representação dinâmica adiciona acessos a ponteiros e muda a disposição das linhas. Em -O0, esses custos podem contribuir para a diferença de tempo. Os contadores medidos ajudam a interpretar o resultado, mas não isolam uma causa única.

3. Cache e desvios: resultados das oito versões




Figura 2 — Leituras e faltas de leitura na L1 de dados; médias e IC95%.




Figura 3 — Instruções de desvio e erros de predição; médias e IC95%.

Exp.	L1 loads (milhões)	L1 misses (milhões)	Branch instr. (milhões)	Branch misses (milhares)
E1	2.431,673 ± 1,029	136,701 ± 0,045	135,27130 ± 0,00012	264,327 ± 0,229
E2	3.100,986 ± 0,205	141,394 ± 0,345	135,27109 ± 0,00012	264,235 ± 0,172
E3	2.427,550 ± 0,075	8,673 ± 0,008	135,27115 ± 0,00010	263,940 ± 0,119
E4	3.098,614 ± 0,059	8,773 ± 0,017	135,27109 ± 0,00013	264,163 ± 0,147
E5	2.299,933 ± 1,639	137,124 ± 0,042	68,42449 ± 0,00010	264,139 ± 0,147
E6	2.902,646 ± 0,418	143,973 ± 0,320	68,42441 ± 0,00013	264,281 ± 0,268
E7	2.588,463 ± 0,210	138,718 ± 0,046	147,48992 ± 0,00010	138,133 ± 0,397
E8	3.128,285 ± 0,247	1,932 ± 0,152	147,48981 ± 0,00012	138,018 ± 0,348

Cache: interchange reduziu as faltas de L1 em cerca de 94% nas duas alocações, coerente com o acesso sequencial às linhas de B e da saída. Tiling teve comportamento diferente entre as alocações: E7 manteve muitas faltas e E8 reduziu-as fortemente. Conflitos de cache associados ao passo das linhas são uma hipótese, ainda não comprovada.

Desvios: unrolling reduziu as instruções de desvio em aproximadamente 49%, mas os erros de predição ficaram próximos de 264,2 mil. Portanto, menos desvios não significaram redução proporcional dos erros nem ganho garantido de tempo.

4. Influência da técnica, alocação e interação

Seguindo o material R [5], foram analisados dois planejamentos 2^2 : **E1-E4 para cache** (simples × interchange) e **E1,E2,E5,E6 para branch** (simples × unrolling). O segundo fator é estática × dinâmica. A interação mede se o efeito da técnica muda conforme a alocação.

O modelo é $y = q_0 + q_A \cdot A + q_B \cdot B + q_{AB} \cdot A \cdot B$, com níveis $-1/+1$. A influência do material é $100 \cdot q^2 / (q_A^2 + q_B^2 + q_{AB}^2)$. Ela reparte a variação entre as quatro médias; **não é o percentual de melhora de desempenho**. A adaptação em R usa `lm` e `anova` e reproduziu os resultados de Python.

Métrica	Técnica (%)	Alocação (%)	Interação (%)
L1 loads	0,002	99,997	0,000
L1 misses	99,935	0,034	0,031
Branch instr.	100,000	0,000	0,000
Branch misses	25,866	3,217	70,918

Tabela 3 — Influências calculadas como no script de apoio, considerando as quatro médias.




Figura 4 — Análise adicional das 40 observações de cada subconjunto, incluindo o erro entre repetições.

Métrica	Técnica (%)	Alocação (%)	Interação (%)	Resíduo (%)
L1 loads	0,002	99,997	0,000	0,000
L1 misses	99,934	0,034	0,031	0,001
Branch instr.	100,000	0,000	0,000	0,000
Branch misses	1,527	0,190	4,188	94,095

Tabela 4 — Com réplicas: $SQ_{fator} = 4 \cdot 10 \cdot q^2$; SQ_{erro} soma os desvios quadráticos dentro de cada combinação. Percentuais divididos pela soma de quadrados total. Valores muito pequenos podem arredondar para 0,000%.

Interpretação: a alocação domina a variação das leituras de L1; a técnica domina as faltas de L1 e o total de instruções de desvio. Em branch misses, 94,09% da variação total é resíduo entre execuções. Por isso, os 70,92% de interação da Tabela 3 não devem ser entendidos como grande ganho ou evidência forte de efeito.

5. Limitações e conclusão




Figura 5 — Tempos por rodada. As primeiras observações mais lentas foram mantidas.

Mudança durante a coleta. A primeira rodada teve média de 0,937 s por execução; da terceira em diante, 0,461 s. Essa diferença sugere mudança nas condições de execução. Sem medir frequência, temperatura e carga durante cada execução, não é possível determinar a causa. Todas as observações foram mantidas.

Limites da comparação. Os processos foram registrados no início e no fim da coleta. O processo firefox apareceu nos dois registros. O notebook estava na bateria nos dois momentos. Esses registros não medem a carga instantânea de cada aplicativo. A CPU irmã não foi isolada e a frequência não foi fixada. Os ICs t são individuais e pressupõem estabilidade e independência suficientes. A mudança de tempo durante a coleta limita essa interpretação; uma média menor não significa uma medição mais estável.

O estudo usa um único tamanho de matriz e de bloco. A dimensão 512, potência de dois, pode acentuar conflitos de cache. Os resultados não devem ser generalizados para todas as dimensões, compiladores ou arquiteturas. A medição inclui zeramento e primeira escrita da saída, mas exclui malloc/free: avalia principalmente a disposição e o acesso às matrizes, não o custo de alocá-las.

Conclusão. Interchange estático apresentou o menor tempo médio e reduziu fortemente as faltas de L1. Unrolling quase dividiu por dois as instruções de desvio, mas não garantiu ganho na versão dinâmica. Tiling dependeu da disposição em memória. A análise das repetições mostrou que diferenças pequenas em branch misses exigem cautela.

Reprodução. O repositório preserva as 80 medições em dados/coleta_vscode/medicoes.csv. As tabelas completas e os gráficos estão em analise/; brutos/ contém as saídas originais e fontes/, o código usado. O piloto anterior foi preservado separadamente em historico/piloto.zip. O comando **make relatorio COLETA=dados/coleta_vscode** recalcula a análise e a conferência em R e gera este PDF e o Anexo_tecnico.pdf.

O anexo contém a metodologia completa e os gráficos de efeitos principais e interação. Os arquivos preservados têm verificação SHA-256; o relatório usa os dados medidos, sem descartar observações.

Referências

- [1] SSC0951. Atividade relativa à aula 3 (Profiling). Enunciado: Atividade_1.pdf.
- [2] BRUSCHI, Sarita Mazzini. 3ª aula — Profiling, páginas 14–17. 3aAula_Profiling.pdf.
- [3] Linux perf. [perf-stat\(1\)](#): controle dos eventos e coleta em modo usuário.
- [4] NIST/SEMATECH. [Confidence Limits for the Mean](#). IC bilateral t de Student.
- [5] SSC0951. Script R de apoio: r.txt, preservado em Ex1/material_apoio/r_original.txt. Adaptação: Ex1/scripts/validar_analise.R.