

Multiplicação de matrizes e análise de desempenho

SSC0951: Desenvolvimento de Código Otimizado

Fernando Alee Suaiden: Nº USP 12680836

Bruno Dalcantoni Cozac: Nº USP 13686323

1. Implementação e medições

Foram comparadas quatro implementações seriais da multiplicação de matrizes, cada uma com alocação estática e dinâmica, totalizando os oito experimentos do enunciado. Cada elemento da saída soma os produtos de uma linha de A por uma coluna de B.

Estática	Dinâmica	Técnica	Implementação
E1	E2	Simples	Laços $i \rightarrow j \rightarrow k$
E3	E4	Interchange	Troca para $i \rightarrow k \rightarrow j$
E5	E6	Unrolling	Duas operações por iteração de k
E7	E8	Tiling	Blocos de 32 em cada dimensão

Tabela 1: Técnicas e modos de alocação dos oito experimentos.

Configuração. Matrizes 512×512 de float, entradas idênticas e compilação GCC 15.3.1 com -O0 em todas as versões, mantendo desativadas as principais otimizações automáticas do compilador. Unrolling e tiling são explícitos, sem OpenMP. As matrizes estáticas são contíguas; as dinâmicas usam um vetor de ponteiros e uma alocação por linha.

Máquina. AMD Ryzen 7 5700U (8 núcleos/16 CPUs lógicas), Fedora 43, kernel e perf 7.1.13. A L1 de dados tem 32 KiB por núcleo e a L2, 512 KiB. O programa usou uma thread fixada na CPU lógica 2. Frequência e boost permaneceram sob controle do sistema.

Coleta. Cada um dos oito experimentos foi executado dez vezes, em ordem sorteada: **80 medições**. O tempo mede zeramento da saída e multiplicação. Os quatro contadores do perf foram ativados ao redor desse trecho, em modo usuário, excluindo alocação, geração das entradas e impressão, com pequeno custo de controle. Todos tiveram cobertura de 100%, sem multiplexação. Nenhuma execução foi descartada.

Validação. As oito versões passaram em testes contra uma referência em double, com matrizes densas, identidade e zero, tamanhos ímpares, blocos incompletos e chamadas repetidas. Os resultados também coincidiram nas 80 medições.

Estatística. Para cada métrica e experimento, calculou-se média e intervalo de confiança de 95%: média $\pm 2,262157 \times s/\sqrt{10}$, em que s é o desvio padrão amostral e $s/\sqrt{10}$ é o erro padrão estimado da média. O fator 2,262157 vem da distribuição t de Student com nove graus de liberdade. Nas tabelas, “ $\pm$ ” indica a margem desse intervalo. Os cálculos também foram conferidos em R.

2. Comparação dos tempos




Figura 1: Tempo médio do cálculo e intervalo de confiança de 95%; dez execuções por configuração.

Exp.	Técnica / alocação	Tempo (s): média ± IC95%	Razão simples / versão
E1	Simples / estática	0,483 ± 0,008	1,000×
E2	Simples / dinâmica	0,533 ± 0,008	1,000×
E3	Interchange / estática	0,322 ± 0,004	1,502×
E4	Interchange / dinâmica	0,526 ± 0,004	1,013×
E5	Unrolling / estática	0,408 ± 0,016	1,186×
E6	Unrolling / dinâmica	0,552 ± 0,007	0,965×
E7	Tiling / estática	0,367 ± 0,015	1,318×
E8	Tiling / dinâmica	0,514 ± 0,008	1,036×

Tabela 2: Tempos médios, IC95% e razão em relação à versão simples.

Melhor resultado: interchange estático (E3), com $0,322 \pm 0,004$ s. O tempo médio foi 33,4% menor que o de E1, equivalente a uma razão de 1,50×. Na alocação estática, todas as técnicas tiveram média menor que a versão simples.

Na alocação dinâmica, tiling (E8) teve a menor média: redução de 3,5% em relação a E2. Unrolling dinâmico (E6) teve média 3,6% maior que E2.

A representação dinâmica adiciona acessos a ponteiros e muda a disposição das linhas. Em -O0, esses custos podem contribuir para a diferença de tempo.

3. Cache e predição de desvios

Para cache, foram comparados E1 a E4: simples × interchange. Para predição de desvios, foram comparados E1,E2,E5,E6: simples × unrolling. Cada comparação inclui alocação estática e dinâmica.




Figura 2: Simple × interchange: médias e IC95%.

Exp.	Leituras na L1 (milhões): média ± IC95%	Faltas na L1 (milhões): média ± IC95%
E1	2.431,371 ± 2,540	136,573 ± 0,134
E2	3.101,030 ± 0,157	141,724 ± 0,362
E3	2.427,471 ± 0,058	8,668 ± 0,007
E4	3.098,770 ± 0,140	8,753 ± 0,016

Tabela 3: Contadores: simples × interchange, nas duas alocações.




Figura 3: Simple × unrolling: médias e IC95%.

Exp.	Instruções de desvio (milhões): média ± IC95%	Erros de predição (milhares): média ± IC95%
E1	135,27126 ± 0,00001	264,158 ± 0,112
E2	135,27105 ± 0,00001	264,197 ± 0,075
E5	68,42446 ± 0,00002	264,124 ± 0,115
E6	68,42436 ± 0,00001	264,164 ± 0,075

Tabela 4: Contadores: simples × unrolling, nas duas alocações.

Cache: interchange reduziu as faltas de L1 em 93,7% na alocação estática e 93,8% na dinâmica. A redução é coerente com a ordem i-k-j, que percorre sequencialmente as linhas de B e da saída.

Desvios: unrolling reduziu as instruções de desvio em aproximadamente 49%, mas os erros de predição ficaram próximos de 264,2 mil. Expandir duas operações por iteração reduz o controle do laço, sem reduzir os erros de predição na mesma proporção.

4. Influência da técnica, alocação e interação

Foram analisados dois planejamentos 2^2 : **E1 a E4 para cache** (simples × interchange) e **E1,E2,E5,E6 para branch** (simples × unrolling). O segundo fator é estática × dinâmica. A interação mede se o efeito da técnica muda conforme a alocação.

O modelo é $y = q_0 + q_A \cdot A + q_B \cdot B + q_{AB} \cdot A \cdot B$. A representa a técnica (−1 simples, +1 otimizada) e B, a alocação (−1 estática, +1 dinâmica). A influência entre médias é $100 \cdot q^2 / (q_A^2 + q_B^2 + q_{AB}^2)$. O percentual expressa a contribuição de cada fator para a variação entre as quatro médias. Os cálculos foram conferidos em R com lm e anova.

Métrica	Técnica (%)	Alocação (%)	Interação (%)
L1 loads	0,002	99,998	0,000
L1 misses	99,922	0,040	0,038
Branch instr.	100,000	0,000	0,000
Branch misses	42,260	57,716	0,024

Tabela 5: Influências considerando a variação entre as quatro médias.

Interpretação: a alocação domina a variação das leituras de L1; a técnica domina as faltas de L1 e o total de instruções de desvio.

Em branch misses, a alocação respondeu por 57,72% da variação entre médias, a técnica por 42,26% e a interação por 0,024%. A diferença simples – unrolling foi de 34,6 erros na alocação estática e 33,0 na dinâmica, diante de cerca de 264,2 mil erros por execução. Os intervalos dessas médias se sobrepõem.

5. Conclusão

Interchange estático apresentou o menor tempo médio e reduziu fortemente as faltas de L1. Unrolling reduziu as instruções de desvio pela metade, aproximadamente; na versão dinâmica, seu tempo médio foi maior que o da versão simples. Entre as versões dinâmicas, tiling apresentou o menor tempo médio.

Referências

BRUSCHI, Sarita Mazzini. 3ª aula: Profiling, páginas 14 a 17. 3aAula_Profiling.pdf.

Linux perf. [perf-stat\(1\)](#): controle dos eventos e coleta em modo usuário.

NIST/SEMATECH. [Confidence Limits for the Mean](#). IC bilateral t de Student.

SSC0951. Script R de apoio para cálculo das influências: r.txt.